

Octubre 2025

Análisis exploratorio de
proyectos Datathon y FORVIA

REGRESIÓN LOGÍSTICA

FORVIANOS.py

FORVIANOS . PY



Maria Matanzo

A 01737554



Jorge Cortes

A 01736236



Marco Cornejo

A 01276411



Eduardo Torres

A 01734935



Laisha Puan

A 01736397

OBJETIVOS

- Aplicar Regresión Logística para analizar relaciones entre variables binarizadas.
- Evaluar el desempeño de varios modelos con distintas variables dependientes (Y).
- Medir el rendimiento con Accuracy, Precision, Recall y F1-score.

M E T O D O L O G Í A D E L A S A C T I V I D A D E S

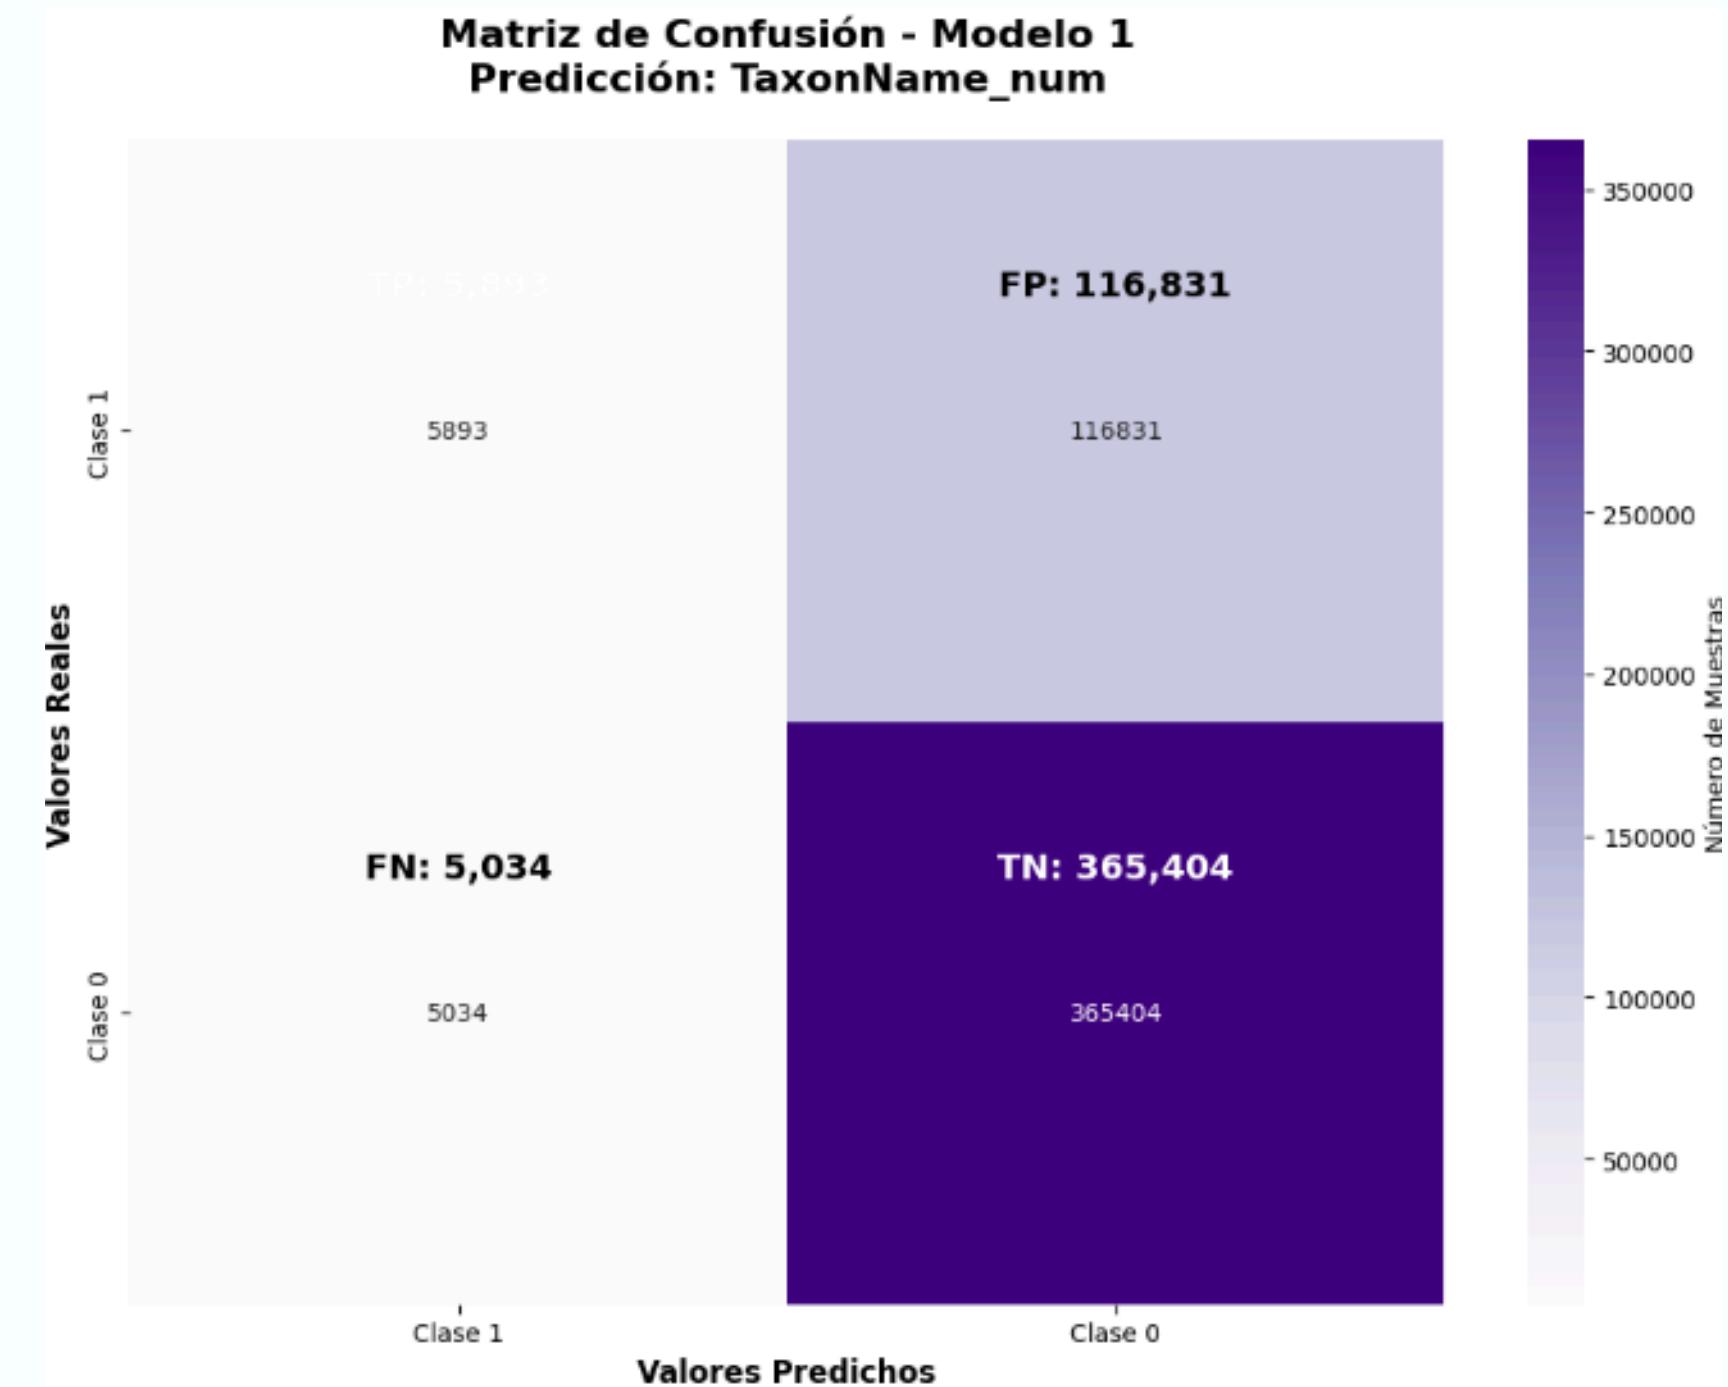
1. Limpieza de datos y tratamiento de valores nulos.
2. Conversión de variables categóricas a numéricas mediante codificación.
3. Binarización (0 o 1) de las variables con base en percentiles o valores centrales.
4. División de datos.
5. Entrenamiento de modelos de Regresión Logística.
6. Evaluación de desempeño con Accuracy, Precision, Recall y F1-score.
7. Interpretación de resultados y detección de sesgos o desbalance.

MODELO PREDICCIÓN DE TAXONNAME_NUM

- **Variable dependiente (Y):**
TaxonName_num
- **Variables independientes (X):**
Abundance_nbcell,
TotalAbundance_SamplingOperation,
Abundance_pm
- **Accuracy:** 75.29%
- **Recall Clase 0:** 4.8%

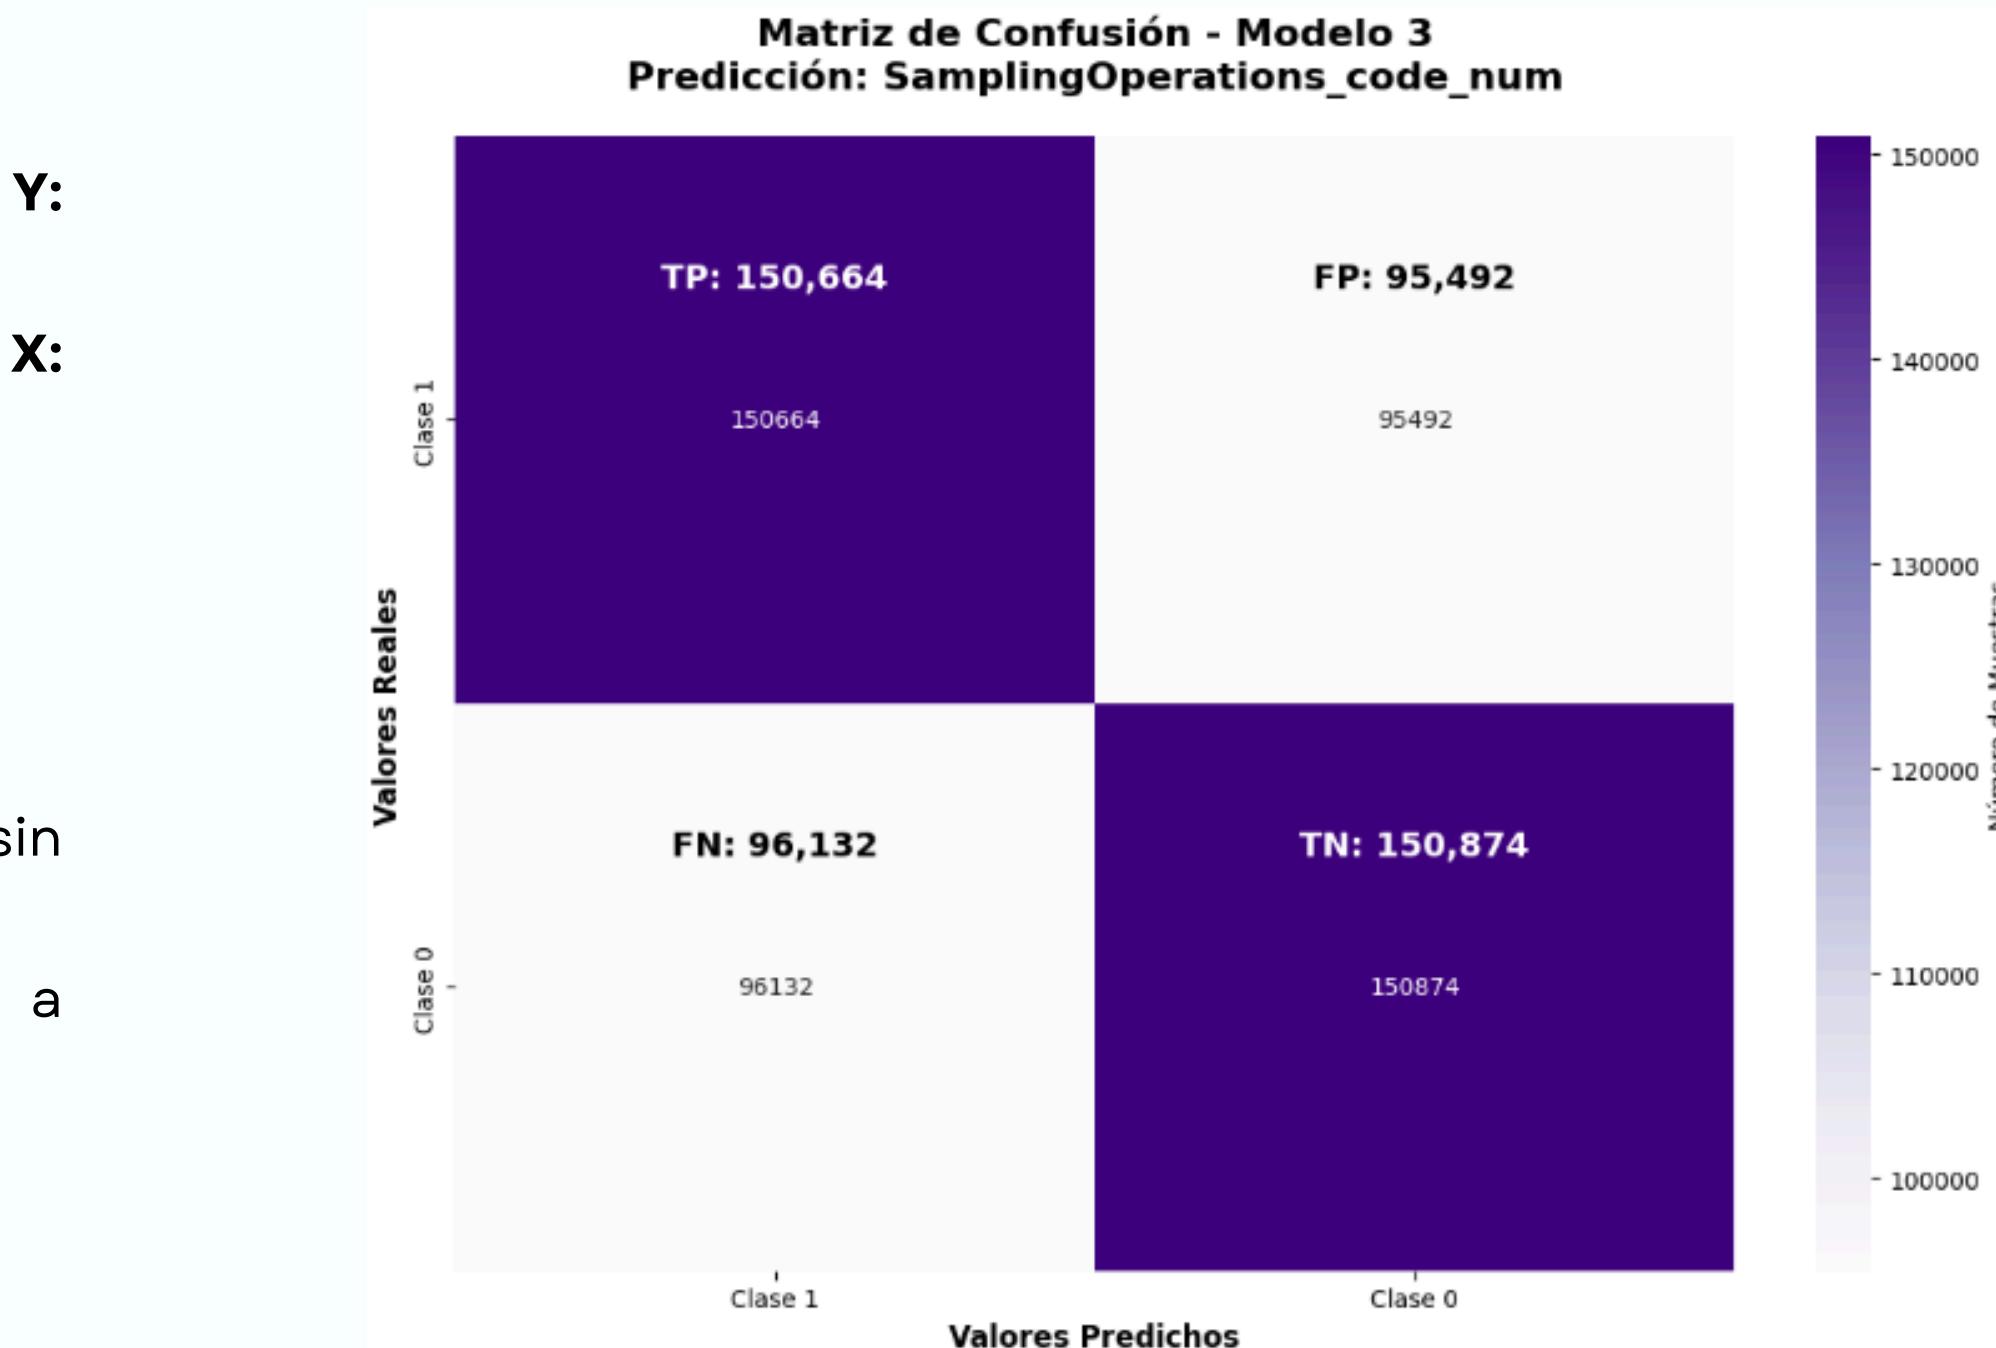
Resultados:

- El modelo tiene alta exactitud, pero falla al identificar la clase minoritaria.
- Gran cantidad de falsos positivos.
- Resultados similares a Taxoncode_num.



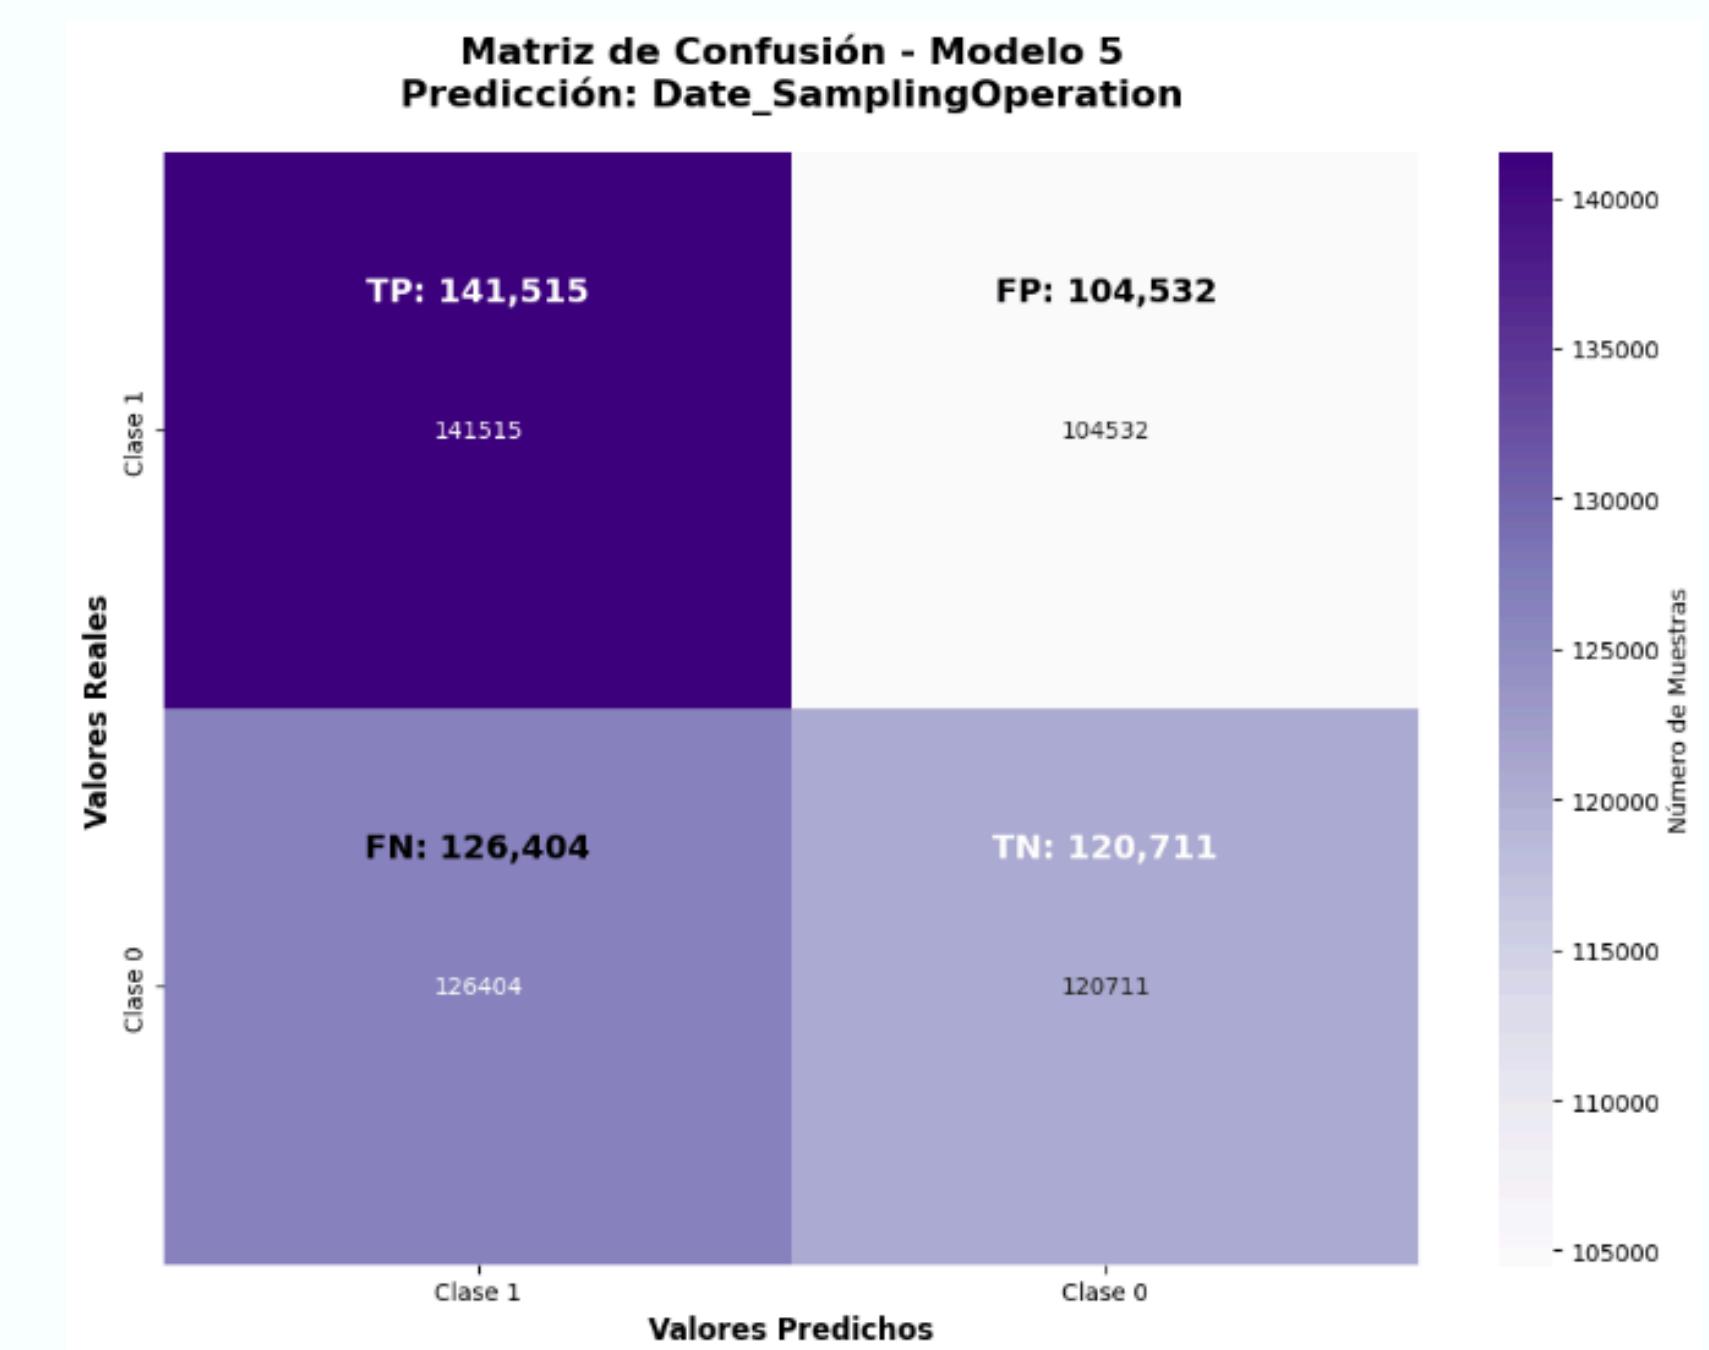
MODELO SAMPLING OPERATIONS _CODE_NUM

- **Variable dependiente**: SamplingOperations_code_num
- **Variables independientes**: CodeSite_SamplingOperations_num, Date_SamplingOperation
- **Accuracy**: 61.14%
- **Recall**: ~61% para ambas clases.
- **Hallazgos**: Métricas equilibradas, sin sesgo notable.
- Resultados similares a CodeSite_SamplingOperations_num.



MODELO DATE_SAMPLING OPERATION

- **Variable dependiente** Y:
Date_SamplingOperation (dicotómica por fecha central)
- **Variable independiente** X:
TotalAbundance_SamplingOperation,
Abundance_pm
- **Accuracy:** 53.17%
- **Recall Clase 0: 57.52% / Recall Clase 1: 48.85%**
- **Interpretación:** Modelo apenas mejor que una conjeta aleatoria.
- Variables de abundancia no correlacionan bien con el tiempo de muestreo.



CONCLUSIONES DATASET DATATHON

1. Modelos 1 y 2: exactitud alta pero recall mínimo → desbalance extremo.
2. Modelos 3 y 4: rendimiento balanceado (~61%).
3. Modelo 5: sin correlación temporal significativa.
4. En general: correlaciones débiles y sesgo hacia clases mayoritarias.

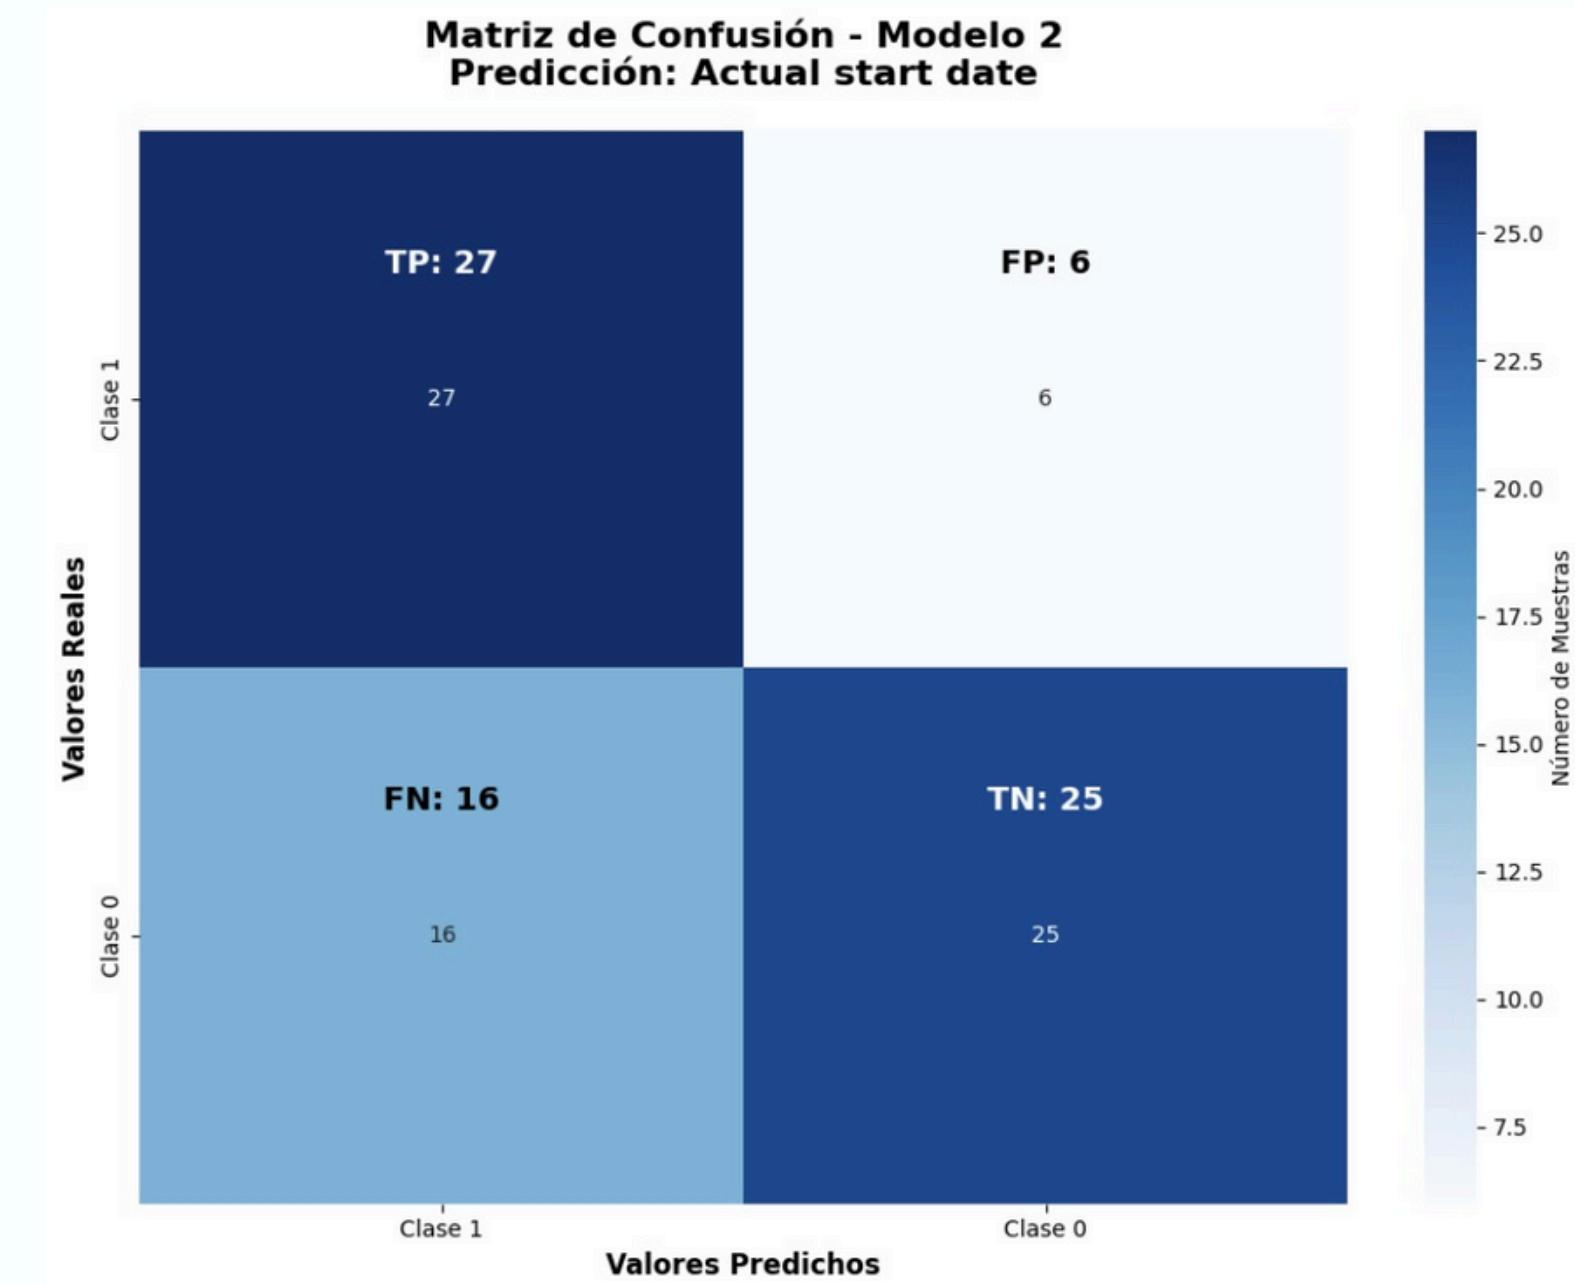
ACTIVIDAD 4.2

FORVIANOS.py

M O D E L O A C T U A L

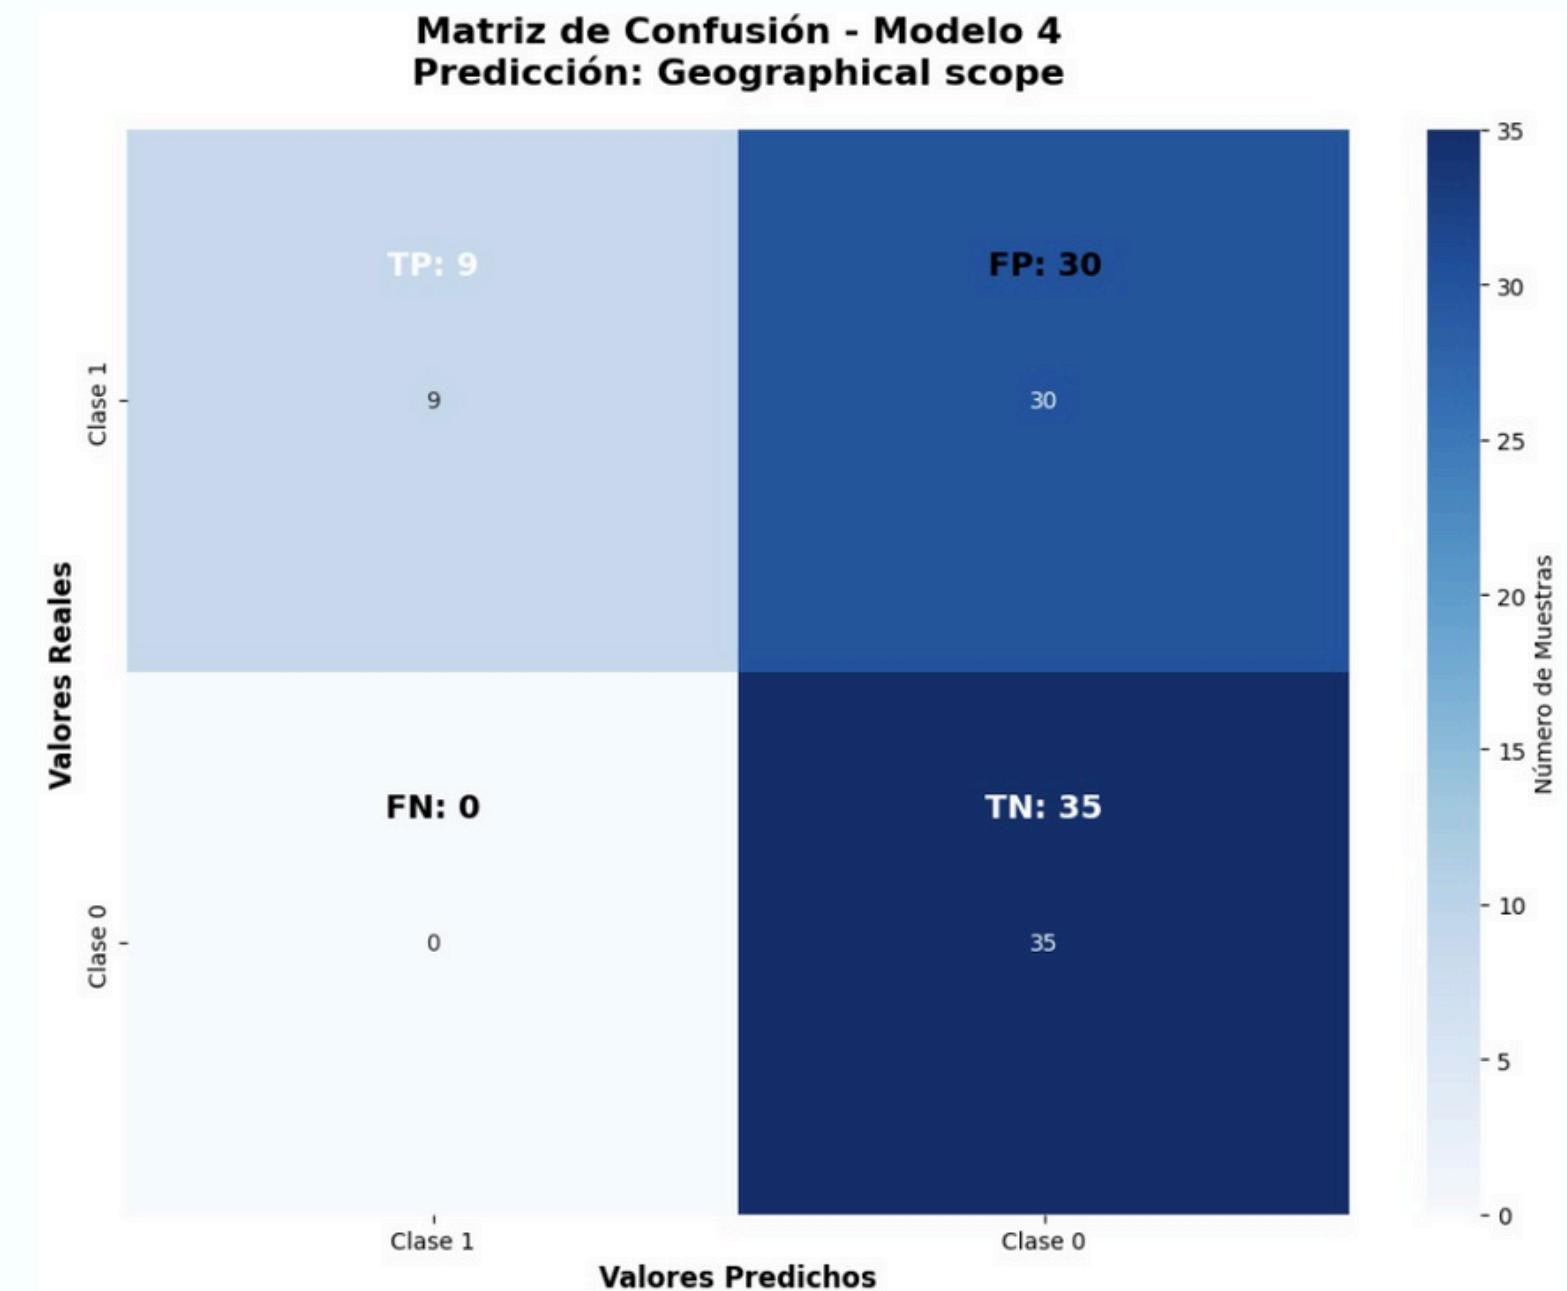
S T A R T D A T E

- **Variables:**
- **Y:** Actual start date (dicotómica)
- **X:** Geographical scope, Planned start date, Percent complete
- **Accuracy:** 63.51%
- **Precisión Clase 1:** 67.50%
- **Recall Clase 1:** 65.85%
- **Conclusión:** Es el modelo con mejor rendimiento general, con buen equilibrio entre precisión y sensibilidad.



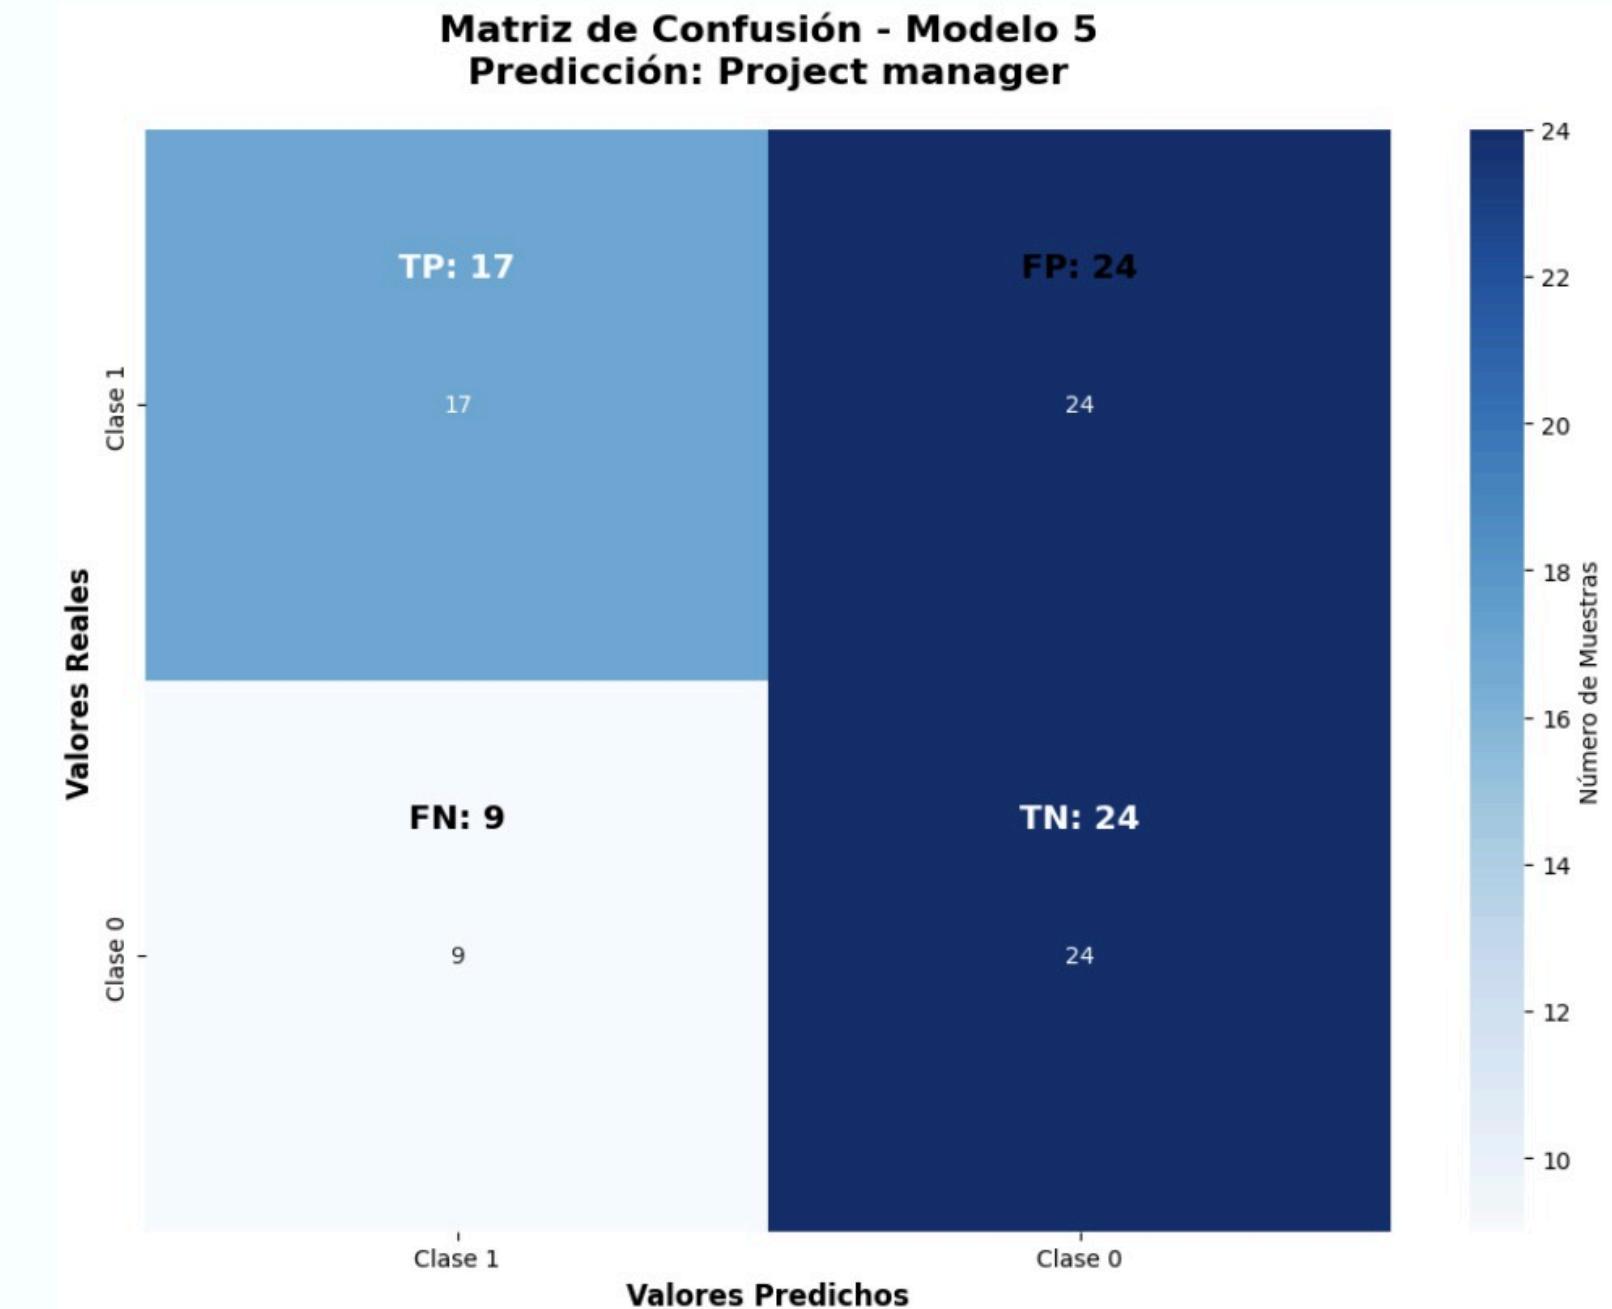
MODELO GEOGRAPHICAL SCOPE

- **Variables:**
 - **Y:** Geographical scope (dicotómica)
 - **X:** Percent complete, Actual start date
- **Accuracy:** 54.05%
- **Recall Clase 1:** 80%
- **Recall Clase 0:** 30.77%
- **Conclusión:** Modelo sesgado hacia la Clase 1, con baja exactitud global.



MODELO PROJECT MANAGER

- **Variables:**
 - **Y:** Project manager (dicotómica)
 - **X:** Percent complete, Actual start date
- **Accuracy:** 58.11%
- **Recall Clase 1:** 50.00%
- **Recall Clase 0:** 66.67%
- **Conclusión:** Desempeño cercano al azar; el modelo tiende a predecir más la Clase 0, mostrando bajo poder predictivo y ligero sesgo.



CONCLUSIONES DATASET FORVIA

1. Mejor modelo: Caso 2 (Actual start date, 63.51% accuracy).
2. Casos 3 y 4 presentan sesgos fuertes entre clases.
3. Casos 1 y 5: desempeño cercano al azar.
4. Correlaciones moderadas, pero problemas de balance de clases afectan el resultado.

CONCLUSIONES

La Regresión Logística permite explorar correlaciones binarias, pero su éxito depende del balance y calidad de datos.

- Ambos conjuntos presentan exactitud moderada (50-63%), mostrando que las correlaciones entre variables son parciales.

En general, se observó que algunos modelos logran un desempeño equilibrado, mientras que otros presentan sesgo hacia una de las clases o un comportamiento cercano al azar, lo que refleja la complejidad de los datos y la necesidad de un análisis más profundo en futuras etapas.

Octubre 2030

MUCHAS
GRACIAS

Bruno Lago